✦ GUIDE COMPLET 2026 ✦

Construire des Agents Intelligents qui Travaillent Pour Toi

■ Agents IA ■ Mémoire persistante ■ Monétisation

Par Enzo Laurenceau — Fondateur PromptFlow

promptflow.fr

Table des matières

1.	Pourquoi l'IA ordinaire ne suffit plus	5
2.	Ce qu'est vraiment un agent IA	8
3.	La mémoire : le super-pouvoir que personne ne t'explique	12
4.	Orchestrer plusieurs agents ensemble	16
5.	Comment les agents s'auto-évaluent	20
6.	Utiliser les LLMs sans exploser ton budget	24
7.	Architecture pratique : ta propre Forge en 5 blocs	28
8.	Monétiser : passer de l'outil au business	33
9.	Ton plan d'action 30 jours	38

Chapitre 1 — Pourquoi l'IA ordinaire ne suffit plus

> *"Je ne voulais pas juste utiliser l'IA. Je voulais comprendre comment la faire travailler à ma place, 24h/24, sans se tromper."*

Tu as essayé ChatGPT. Tu as été impressionné les premières fois. Puis tu as réalisé que tu passais plus de temps à reformuler tes prompts qu'à produire de vraie valeur.

Le problème n'est pas toi. C'est l'approche.

Les 3 limites fatales de l'IA conversationnelle

1. Elle oublie tout. À chaque nouvelle conversation, tu repars de zéro. Ton contexte, tes préférences, ton historique — disparus. Tu répètes les mêmes explications en boucle.

2. Elle fait une chose à la fois. Tu lui demandes d'analyser, elle analyse. Mais pour enchaîner dix étapes d'un workflow complexe, c'est toi qui fais le lien à chaque fois.

3. Elle ne s'améliore pas. Une conversation de GPT aujourd'hui est aussi vierge que ta première il y a deux ans. Aucune capitalisation sur ce que tu as appris ensemble.

La solution : les systèmes d'agents

Un agent IA, c'est une IA à laquelle tu donnes un objectif, des outils, et de la mémoire. Au lieu de répondre à une question, elle *accomplit une mission*.

	IA conversationnelle	Système d'agents
Interaction	Tu poses une question	Tu définis un objectif
Mode	Elle répond une fois	Elle travaille en boucles
Mémoire	Aucune	Persistante entre sessions
Modèles	Un seul LLM	Plusieurs spécialistes
Coordination	Tu gères tout	Elle s'auto-coordonne

■ À retenir : Ce guide t'explique comment construire le deuxième type de système — même sans être développeur.

Chapitre 2 — Ce qu'est vraiment un agent IA

Un agent, c'est une IA avec trois ingrédients supplémentaires : des **outils**, une **mémoire**, et une **boucle de raisonnement**.

Les outils

Sans outils, un LLM ne fait que générer du texte. Avec des outils, il peut agir dans le monde réel. Exemples concrets : chercher sur Google ou Semrush, lire et écrire des fichiers, envoyer des emails via Gmail, créer des produits sur Shopify, appeler d'autres APIs.

La boucle de raisonnement (ReAct)

Un agent ne répond pas en ligne droite. Il réfléchit, agit, observe le résultat, et recommence — jusqu'à avoir accompli la mission.

```
Objectif ↓ [RÉFLÉCHIR] → Quelle est la prochaine action ? ↓ [AGIR] → Utiliser un outil ↓ [OBSERVER] → Analyser le résultat ↓ Objectif atteint ? → Non → retour à RÉFLÉCHIR → Oui → STOP
```

Les 7 agents spécialistes de la Forge

Agent	Spécialité
HUNTER	Trouve des opportunités de marché (niches, tendances)
BUILDER	Crée les livrables (pages, produits, contenus)
MARKET	Recherche de mots-clés et analyse concurrentielle
CRITIC	Évalue la qualité du travail des autres agents
CLOSER	Gère prospection B2B et séquences emails
MARKETING	Contenus réseaux sociaux et campagnes
AUDIT	Analyse code et systèmes pour détecter problèmes

■ À retenir : Un agent = un objectif + des outils + une mémoire + une boucle. Ce n'est pas de la magie — c'est de l'organisation.

Chapitre 3 — La mémoire : le super-pouvoir que personne ne t'explique

C'est ici que la plupart des tutoriels s'arrêtent trop tôt — et c'est pourtant le plus important.

Un agent sans mémoire, c'est un employé qui arrive chaque matin sans souvenir de ce qui s'est passé la veille. Excellent individuellement, mais impossible à faire progresser.

Les 3 types de mémoire

Type	Durée	Usage
Session	Conversation en cours	Cohérence d'une tâche unique
Structurée (Graphify)	Persistante	Findings, règles, résultats validés
Sémantique (OpenViking)	Persistante	Retrouver par sens, pas par mot-clé

Graphify + OpenViking : la combinaison gagnante

Graphify stocke les findings confirmés, les règles apprises, l'historique des cycles. **OpenViking récupère** les informations les plus pertinentes par scoring sémantique avant chaque appel LLM.

```
Score de pertinence d'un noeud : keyword_score (50%) → mots-clés de la query présents dans le contenu recency_score (30%) → noeuds récents favorisés task_affinity (20%) → bonus si même type de tâche Filtre qualité : score < 4.5/10 → exclu automatiquement
```

L'effet cumulatif

Un système avec mémoire s'améliore à chaque cycle. Après 10 cycles sur la même niche, l'agent MARKET sait déjà quels mots-clés sont saturés, quels angles de contenu performent. Il n'a pas besoin qu'on lui réexplique.

> **■ À retenir : Investir dans la mémoire de ton système d'agents est l'amélioration au plus fort ROI. Un agent sans mémoire progresse à 0. Un agent avec mémoire progresse de façon composée.**

Chapitre 4 — Orchestrer plusieurs agents ensemble

Avoir un bon agent, c'est bien. En avoir plusieurs qui travaillent ensemble sans se marcher dessus, c'est une forge.

LangGraph : le chef d'orchestre

LangGraph est le framework qui connecte plusieurs agents en un **graphe de travail**. Chaque agent est un nœud, et les connexions entre eux définissent l'ordre et la logique d'exécution.

```
python run_forge.py --task "analyser la niche IA créateurs"
■■■
```

Chapitre 5 — Comment les agents s'auto-évaluent

Voici une problématique que peu de gens abordent : comment savoir si ce qu'un agent produit est vraiment bon ?

Le jury MiroFish

MiroFish est un système d'évaluation par personas multiples. Avant de valider un output, trois juges fictifs l'analysent depuis des angles différents :

Persona	Angle d'analyse
L'Expert	Profondeur technique et pertinence
Le Sceptique	Failles, approximations, manques
L'Utilisateur Final	Utilité réelle et compréhensibilité

Score	Verdict	Action
≥ 7/10	APPROUVÉ ■	Passer à l'étape suivante
5 – 7/10	RÉVISION ■	L'agent retravaille l'output
< 5/10	REJETÉ ■	Finding archivé, nouvelle tentative

L'auto-complexification

Au-delà de la validation, le système mesure la *tendance* de la qualité dans le temps. Si les scores s'améliorent sur plusieurs cycles, le système monte en niveau automatiquement (L1 → L2 → L3 → L4), en se fixant des objectifs plus ambitieux.

■ À retenir : Un bon système d'agents inclut toujours une boucle d'évaluation. Sans elle, tu ne sais pas si tu produis de la valeur ou de la quantité.

Chapitre 6 — Utiliser les LLMs sans exploser ton budget

Les LLMs coûtent de l'argent — surtout si tu les utilises massivement dans un système automatisé. Voici comment j'ai résolu ce problème dans la Forge.

La hiérarchie des coûts

Tâche	Modèle	Coût
Résumé, extraction, scoring	OpenRouter free models	Gratuit
Génération de contenu	Claude Haiku	~0,001€/appel
Analyse, recherche	Claude Sonnet	~0,05€/appel
Orchestration, critique	Claude Opus	~0,20€/appel

OpenRouter : le multiplicateur

OpenRouter agrège plus de 200 modèles (dont beaucoup gratuits) derrière une seule API. Dans la Forge, c'est la première couche testée avant tout appel payant : environ 800 millions de tokens gratuits par mois.

```
Ordre de priorité dans forge_llm.py : 1. OpenRouter (200+ modèles, quota maximal) ← PRIORITAIRE 2. Gemini Flash direct (backup) 3. Groq Llama-4 direct (ultra-rapide) 4. Cerebras direct (secours) 5. Claude Haiku/Sonnet/Opus via OpenRouter
```

La règle des 80/20

80% des appels LLM dans un système d'agents sont des tâches légères (scoring, extraction, formatage, résumé). Ces 80% tournent sur des modèles gratuits. Seuls les 20% de tâches complexes méritent un modèle premium.

Résultat : un système qui tourne 8h/jour reste sous **20€/mois**.

■ À retenir : Ne fais pas tourner un V8 pour aller chercher du pain. Match la puissance au besoin, utilise OpenRouter en premier, et mesure tout avec le token tracker.

Chapitre 7 — Architecture pratique : ta propre Forge en 5 blocs

Tu n'as pas besoin de reproduire exactement ce que j'ai construit. Mais ces 5 blocs te permettent de construire n'importe quel système d'agents.

01

L'état partagé (ForgeState)

Le document central que tous tes agents partagent : tâche en cours, résultats, historique, indicateurs qualité. En pratique : un dictionnaire Python TypedDict passé de nœud en nœud.

02

Les agents spécialisés

Chaque agent = un prompt système + des outils + une logique. La clé est la spécialisation : un agent qui fait une chose très bien vaut mieux que dix agents qui font tout moyennement.

03

La mémoire persistante

Graphify stocke findings et règles entre sessions. OpenViking récupère les informations les plus pertinentes avant chaque LLM. En pratique : un fichier JSON + fonctions read/write.

04

Le jury qualité (MiroFish)

Avant de valider tout output, trois personas évaluent automatiquement. Seuls les outputs ≥ 7/10 passent. En pratique : un sous-graphe LangGraph appelé par chaque agent.

05

Orchestrateur + auto-évolution

L'orchestrateur décide quel agent activer. L'auto-complexification monte le niveau d'exigence si les résultats s'améliorent. En pratique : deux nœuds LangGraph avec logique de routing.

```
python run_forge.py --task "market_scan niche IA créateurs" # → Token estimate affiché # → Cycle exécuté (HUNTER → MARKET → CRITIC → AUTO_COMPLEX) # → Token actual + efficiency score # → Findings sauvés dans 06_FINDINGS/confirmed/
```

■ À retenir : 5 blocs. Commence par les deux premiers et ajoute les autres progressivement.

Chapitre 8 — Monétiser : passer de l'outil au business

Modèle 1 — Les produits digitaux

Crée une fois, vends à l'infini. Pas de stock, pas de logistique, marge quasi 100%. Les agents t'aident à identifier des niches, créer le contenu, optimiser les listings SEO, rédiger les séquences emails, analyser les performances.

Revenus cibles : 27€ × 25 ventes/mois = 675€/mois avec un seul produit.

Modèle 2 — Les services automatisés

Tu vends un service, mais tes agents font 80% du travail : audit SEO automatisé pour PME, rédaction de contenus LinkedIn/TikTok en série, prospection B2B personnalisée, analyse concurrentielle sur demande.

Tu vends une prestation au prix d'un humain, mais le coût marginal est quasi nul après le premier client.

Modèle 3 — L'Agent-as-a-Service

Tu loues l'accès à ton système d'agents à d'autres entrepreneurs. Au lieu de vendre des outputs, tu vends l'infrastructure. C'est le modèle le plus scalable — à viser en phase 2 ou 3.

Le flywheel vertueux

```
Agents génèrent du contenu ↓ Contenu attire du trafic organique ↓ Trafic → ventes produits ↓
Revenus → amélioration des agents ↓ Meilleurs agents → meilleur contenu → ↑
```

■ À retenir : Les agents n'améliorent pas ta stratégie. Ils amplifient l'exécution. Commence par automatiser un flux que tu maîtrises déjà.

Chapitre 9 — Ton plan d'action 30 jours

Semaine 1 — Comprendre et préparer

- Installe Python 3.11+ et crée un environnement virtuel
- Crée un compte OpenRouter (gratuit) → récupère ta clé API
- Installe LangGraph : pip install langgraph langchain-anthropic
- Définis TA première tâche : qu'est-ce que tu veux automatiser en priorité ?

Semaine 2 — Construire les fondations

- Crée ton ForgeState minimal (5 champs : task, cycle, findings, quality, next_agent)
- Code ton premier agent (juste un nœud qui lit l'état et le logue)
- Ajoute un deuxième agent spécialisé et connecte les deux avec LangGraph
- Lance ton premier cycle complet

Semaine 3 — Ajouter la mémoire

- Crée ton fichier graph.json (commence avec un tableau vide)
- Code une fonction save_finding(content, score) qui écrit dedans
- Code une fonction get_context(query) qui lit et filtre
- Lance 3 cycles et vérifie que la mémoire s'accumule

Semaine 4 — Monétiser

- Identifie le produit ou service que ton système peut générer
- Crée un premier prototype de produit digital
- Mets-le en vente (prix de lancement réduit)
- Analyse les résultats et itère

Chapitre — Conclusion

Ce que tu viens de lire n'est pas de la théorie. C'est la documentation vivante d'un système réel, construit brique par brique sur plusieurs mois.

Les agents IA ne remplacent pas ta créativité ou ton jugement. Ils **amplifient ta capacité d'exécution** — faire en 2 heures ce qui prenait 2 semaines, tester 10 idées en parallèle, capitaliser sur chaque apprentissage.

Le plus grand obstacle n'est pas technique. C'est de commencer.

> *"Prends la tâche la plus répétitive de ton workflow actuel. Et commence par automatiser ça. Le reste suivra."*

■ Bonus offert aux lecteurs

→ Template ForgeState prêt à l'emploi (téléchargeable)
→ Code promo **FORGE27** pour 20% de réduction sur tout le catalogue PromptFlow
→ Communauté privée : partage tes premiers agents et obtiens du feedback

promptflow.fr

© 2026 PromptFlow — promptflow.fr